

1-RECOLECCIÓN DE DATOS





RECOLECCIÓN DE DATOS.

“Forma en la que obtenemos datos/información que nos permite obtener conocimiento de primera mano e ideas sobre el problema de investigación”





TIPOS DE RECOLECCIÓN DE DATOS





TIPOS DE ENTREVISTAS. ESTRUCTURADA

ENTREVISTA ESTRUCTURADA

- RÍGIDAS
- ESTANDARIZADAS. PREGUNTAS DEFINIDAS PREVIAMENTE EN BASE A INFO REQUERIDA
- OBJETIVO: MANTENER UNIFORMIDAD DE TODAS LAS SESIONES DE ENTREVISTAS
- PUEDE INCLUIR PREGUNTAS CERRADAS ABIERTAS



TIPOS DE ENTREVISTAS. SEMIESTRUCTURADA

ENTREVISTA SEMIESTRUCTURADA

- DAN MARGEN DE MANIOBRA AL INVESTIGADOR
- MANTIENE LA ESTRUCTURA BÁSICA DE LA ENTREVISTA
- IDEAL CUANDO HAY POCO TIEMPO PARA PREPARAR LA ENTREVISTA, PERO REQUIERE INFORMACIÓN DETALLADA
- DEPENDE EN BUENA PARTE DE LA CREATIVIDAD DEL INVESTIGADOR



TIPOS DE PREGUNTAS. EJEMPLOS.

PREGUNTAS CERRADAS

¿DISFRUTA USAR NUESTRO SERVICIO?

1. SÍ
2. NO
3. NO LO SÉ

¿SE ESTÁN ABURRIENDO MUCHO EN LA CLASE?

1. UFFFFFFFFFFFFFFFFFFFFFFFFF
2. YYYYYYYYYYYYYY.....
3. NAAAAAAAAAAAAAAAAA

PREGUNTAS ABIERTAS

1. ¿QUÉ OPINA DEL NUEVO PRODUCTO?
2. ¿CÓMO PODEMOS SERVIRLE MEJOR?
3. ¿CÓMO FUERON SUS INICIOS EN LA POLÍTICA?



TIPOS DE RECOLECCIÓN

01

Primaria

Datos colectados de primera mano a través de encuestas, entrevistas, experimentos y otros. Puedo decidir qué recolectar y qué quiero medir. Se tiene total control de los datos.

02

Secundaria

Datos previamente recolectados por una fente primaria externa al usuario. Son de libre acceso. No tengo control sobre lo que se mide o sobre el objetivo del estudio

03

Terciaria

Datos que se adquieren de diversas fuentes externas para crear una base completa con datos secundarios. Ejemplo: Proveedores de datos . No necesariamente asociados al problema de negocio.



TIPOS DE RECOLECCIÓN.EJERCICIO

Cuestionario para medir satisfacción del cliente

Observación y medición del tiempo de reproducción de microorganismos para ntro. Proyecto de investigación

Datos de consumo medidos por el INDEC

Datos de usuarios de internet del banco mundial

Compro base de datos de consumidores de chocolate con diversos orígenes unificados

Datos de comportamiento de compras en distintos países y por distintos canales, relevados de distintas fuentes secundarias para armar una base propia consolidada

Primaria


Secundaria

Terciaria

2-ANÁLISIS EXPLORATORIO



EDA. QUÉ ES Y PARA QUÉ SIRVE?



POR QUÉ UN EDA?

- ❖ ORGANIZAR Y ENTENDER LAS VARIABLES
- ❖ ESTABLECER RELACIONES ENTRE VARIABLES
- ❖ ENCONTRAR PATRONES OCULTOS
- ❖ AYUDA A LA SELECCIÓN DEL MODELO APROPIADO PARA LA NECESIDAD PLANTEADA
- ❖ AYUDA A TOMAR DECISIONES BASADAS EN DATOS

POR QUÉ UN EDA?




WHEN DATA IS IN TABLE FORM

ID	NAME	CLASS	MARK	SEX
1	John Doe	Four	75	female
2	Max Ruhn	Three	85	male
3	Amel	Three	95	male
4	Kish Star	Four	80	female
5	John Mike	Four	60	female
6	Alex John	Four	55	male
7	My John Rob	Fifth	70	male
8	Asad	Five	85	male
9	Tes Gey	Six	70	male
10	Big John	Four	55	female



WHEN DATA IS IN PLOT



2.1-FLUJO DE TRABAJO



PASOS. 1

1

Hacer preguntas

2

Determinar
el tamaño
de los datos

3

Categorizar
las variables

4

Limpieza
y validación
de datos

5

Establecer
relaciones

- ☐ ¿Qué te gustaría encontrar?
- ☐ ¿Qué quisieras saber de los datos?
- ☐ ¿Cuál es la razón para realizar el análisis?

PASOS. 2



- ☐ ¿Cuántas observaciones existen?
- ☐ ¿Cuántas variables hay?
- ☐ ¿Necesito todas las observaciones?
- ☐ ¿Necesito todas las variables?

PASOS. 3



- ☐ ¿Cuántas variables categóricas existen?
- ☐ ¿Cuántas variables continuas existen?
- ☐ ¿Cómo puedo explorar cada variable dependiendo de su categoría?

PASOS. 4



- ☐ ¿Tengo valores faltantes?
- ☐ ¿Cuál es la proporción de datos faltantes?
- ☐ ¿Cómo puedo tratar a los datos faltantes?
- ☐ ¿Cuál es la distribución de los datos?
- ☐ ¿Tengo valores atípicos?

PASOS. 5

1

Hacer preguntas

2

Determinar
el tamaño
de los datos

3

Categorizar
las variables

4

Limpieza
y validación
de datos

5

Establecer
relaciones

- ☐ ¿Existe algún tipo de relación entre mi variable X y Y ?
- ☐ ¿Qué pasa si ahora considero a la variable Z en el análisis?
- ☐ ¿Qué significa que las observaciones se agrupen?
- ☐ ¿Qué significa el patrón que se observa?



VALIDACIÓN DE DATOS

“PROCESO DE ASEGURAR LA CONSISTENCIA Y PRECISIÓN DENTRO DE UN CONJUNTO DE DATOS”

¿QUÉ DEBO VALIDAR PARA ASEGURAR LA CONSISTENCIA?



VALIDAR CONSISTENCIA

MODELO DE DATOS

- ✓ QUÉ PREGUNTAS QUIERO RESPONDER?
- ✓ LOS DATOS QUE RECOLECTO SON ACORDES?

FORMATO ESTÁNDAR ORIGEN DE DATOS

- ✓ EJEMPLO .CSV SEPARADOR , Y . DISTORSIÓN MILES , DECIMALES, CANTIDAD DE COLUMNAS

TIPOS DE DATOS

- ✓ CONSISTENCIA ENTRE DATO ESPERADO Y DATO OBSERVADO. BOOLEANO , DECIMAL = 10

RANGO DE VARIABLES

- ✓ NOTA PARCIAL (0-10), OBSERVACIÓN= -1/ 85



VALIDAR CONSISTENCIA

UNICIDAD

- ✓ 2 ALUMNOS DISTINTOS CON EL MISMO NÚMERO DE DNI

CONSISTENCIA DE EXPRESIONES

- ✓ FORMA DE ESCRIBIR UNA VARIABLE, SEGÚN REGIONES. EJ: FECHAS ARG VS USA (YYYY/DD/MM VS YYYY/MM/DD)
- ✓ SEXO: F/M VS HOMBRE/MUJER

VALORES NULOS

- ✓ VER NA/NULL/ “ ” . CONSIDERAR TIPO DE VARIABLE

VALORES GENÉRICOS

- ✓ FECHA NACIMIENTO: 01/01/1900
- ✓ DNI CLIENTE: 999999999999



VAMOS A COLAB!!!!



https://colab.research.google.com/drive/1RALT9IJ2Zt9uGFWNNuENko4u_kHiWGCH?authuser=3#scrollTo=EXr7oisPb8wp

3-REPRESENTACIONES GRÁFICAS





HISTOGRAMAS

Muy utilizado para presentar los datos de variables

Requieren un tamaño de muestra de al menos 30 casos para ser útiles.

Muestra la forma de la distribución de los datos de la misma manera que la función de densidad muestra las probabilidades


El rango de los valores de los datos es dividido en intervalos-bins y se grafica la cantidad o proporción de observaciones que caen dentro de cada intervalo.




HISTOGRAMAS



Histograma de Frecuencias Relativas con 4 bins



Histograma de frecuencias relativas con 30 bins




Histograma de frecuencias absolutas con 13 bins



ASIMETRÍA

DISTRIBUCIÓN SIMÉTRICA

- Hay el mismo número de elementos a la izquierda y derecha de la media.
- La media, mediana y moda coinciden.
- 'Forma de campana' (distribución normal)






ASIMETRÍA

DISTRIBUCIÓN ASIMÉTRICA A LA IZQUIERDA

- La cola izquierda de la distribución se alarga para los valores por debajo de la media.






ASIMETRÍA

DISTRIBUCIÓN ASIMÉTRICA A LA DERECHA

- La cola derecha de la distribución se alarga para los valores por encima de la media.





BOX-PLOTS (GRÁFICOS DE CAJA)

Gráfica en forma de rectángulo.

Permiten conocer como se distribuyen los datos dentro de una variable.

Aportan más detalles acerca de las colas de la distribución.



Si la distribución es simétrica, los bigotes tendrán la misma longitud en ambos lados de la caja. Sin embargo, si la distribución es sesgada, los bigotes pueden tener longitudes desiguales, lo que indica que hay más valores en una cola que en la otra.



BOX-PLOTS (GRÁFICOS DE CAJA)


La altura del rectángulo: rango intercuartílico. Base inferior: Q1, base superior: Q3, línea a la altura de la mediana: Q2.

Se calcula $1.5 * \text{Rango intercuartílico}$, se dibuja una línea vertical desde la mitad de la parte superior (inferior) del rectángulo hasta la mayor (menor) observación que se encuentre entre ese extremo de la caja y $1.5 * \text{Rango intercuartílico}$.

Las observaciones que caen fuera de esos bigotes se representan con círculos rellenos y son denominados valores atípicos




BOX-PLOTS (GRÁFICOS DE CAJA)







GRÁFICOS DE DISPERSIÓN (SCATTERPLOT)

Permiten observar como se relacionan dos variables.





TIPOS DE CORRELACIÓN.



4-VALORES ATÍPICOS (OUTLIERS)





VALORES ATÍPICOS.OUTLIERS

¿Por qué es importante identificar valores atípicos?

Pueden afectar la interpretación de los datos. El cálculo del coeficiente de correlación puede verse afectado por estos valores y por ende llegar a una conclusión errónea.

EJEMPLO:



*Conjunto con outliers $\rightarrow r = 0.2$

*Conjunto sin outliers $\rightarrow r = 0.8$

¿Cómo podemos detectarlos?



DISTANCIAS DE MAHALANOBIS. EJEMPLO





DISTANCIAS DE MAHALANOBIS.

- Fue introducida por Mahalanobis en 1936.
- Es una forma de determinar la similitud entre dos variables aleatorias
- Tiene en cuenta la correlación entre las variables
- Lenguajes como R o Python la calculan directamente sin necesidad de recurrir a cálculos matriciales “manuales”



DISTANCIAS DE MAHALANOBIS. EJEMPLO

Dataset: Swiss. Medidas de fertilidad e indicadores socioeconómicos para cada una de las 47 provincias de habla francesa de Suiza en 1888.

	Fertility	Agriculture	Examination	Education	Catholic	Infant.Mortality
Courtelary	80.2	17.0	15	12	9.96	22.2
Delemont	83.1	45.1	6	9	84.84	22.2
Franches-Mnt	92.5	39.7	5	5	93.40	20.2
Moutier	85.8	36.5	12	7	33.77	20.3
Neuveville	76.9	43.5	17	15	5.16	20.6
Porrentruy	76.1	35.3	9	7	90.57	26.6
Broye	83.8	70.2	16	7	92.85	23.6
Glane	92.4	67.8	14	8	97.16	24.9

Showing 1 to 9 of 47 entries, 7 total columns



DISTANCIAS DE MAHALANOBIS. EJEMPLO

Anexamos al Dataframe una columna con los valores de la variable MD:

```
MD<- mahalanobis(swiss, colMeans(swiss), Covarianzas_swiss )  
Swiss$MD<-round(MD,3)
```

	Fertility	Agriculture	Examination	Education	Catholic	Infant.Mortality	MD
Courtelay	80.2	17.0	15	12	9.96	22.2	6.916
Delemont	83.1	45.1	6	9	84.84	22.2	4.667
Franches-Mnt	92.5	39.7	5	5	93.40	20.2	7.958
Moutier	85.8	36.5	12	7	33.77	20.3	4.446
Neuveville	76.9	43.5	17	15	5.16	20.6	5.593
Porrentruy	76.1	35.3	9	7	90.57	26.6	12.680
Broye	83.8	70.2	16	7	92.85	23.6	5.972
Glane	92.4	67.8	14	8	97.16	24.9	8.077

Showing 1 to 9 of 47 entries, 7 total columns



DISTANCIAS DE MAHALANOBIS. EJEMPLO

Fijamos como criterio que todos aquellos valores con distancias mayores a 10 son considerados outliers. Agregamos otra columna con valores TRUE o FALSE según superen o no este valor.

	Fertility	Agriculture	Examination	Education	Catholic	Infant.Mortality	MD	outliers
Courtelay	80.2	17.0	15	12	9.96	22.2	6.916	FALSE
Delemont	83.1	45.1	6	9	84.84	22.2	4.667	FALSE
Franches-Mnt	92.5	39.7	5	5	93.40	20.2	7.958	FALSE
Moutier	85.8	36.5	12	7	33.77	20.3	4.446	FALSE
Neuveville	76.9	43.5	17	15	5.16	20.6	5.593	FALSE
Porrentruy	76.1	35.3	9	7	90.57	26.6	12.680	TRUE
Broye	83.8	70.2	16	7	92.85	23.6	5.972	FALSE
Glane	92.4	67.8	14	8	97.16	24.9	8.077	FALSE

Showing 1 to 9 of 47 entries, 8 total columns



DISTANCIAS DE MAHALANOBIS. EJEMPLO

Sin embargo, no es tan simple el proceso de eliminación de outliers, ya que no siempre son errores de medición. Debería hacerse un examen previo. Podría pasar que valores considerados atípicos en una muestra, luego de tomar varias muestras determinen que estos, en verdad, son valores ordinarios.

Sin embargo, muchas veces se cuenta con una sola muestra y poder determinar la causa del valor atípico observado es muy difícil

5-REGRESIÓN LINEAL





REGRESIÓN SIMPLE


El encontrar correlación entre dos variables, nos dice qué tan fuerte es el efecto de un cambio en una sobre la otra?



Podríamos ajustar una línea recta a todos estos datos, para simbolizar los puntos como una ecuación matemática. → Permite cálculo de pendiente → medir la fuerza del efecto: cambio en X vs cambio en Y.



REGRESIÓN SIMPLE




- ❖ La dependencia es de tipo lineal.
- ❖ Se observa cómo la variable Y está relacionada con la variable X.

¿Para qué sirve?

Predicciones en una gran variedad de situaciones, que pueden ser sociales, económicas, biológicas, geofísicas, etc.



REGRESIÓN SIMPLE



- ❖ Los parámetros de la recta se estiman por mínimos cuadrados. Lo que hacen es minimizar el error vertical (distancia entre observación y estimación)



REGRESIÓN SIMPLE. INTERPRETACIÓN

$$y = a + bx + e$$



Altura (y) en función de la edad (x)

Y



Var.
Dependiente



Altura

a



ordenada



Valor de y, cuando $x=0$

b



pendiente



Variación de y, cuando x varía en 1 unidad

X




Var.
Independiente



Edad



REGRESIÓN SIMPLE. INTERPRETACIÓN



Regresión lineal simple de la talla (variable dependiente, “y”) y la edad (variable independiente, “x”).

La recta resume relativamente bien los puntos, pero casi ninguno de ellos está sobre la recta. La distancia entre cada punto y la recta es el residual e para cada punto.



BONDAD DEL AJUSTE

¿QUÉ TAN VÁLIDO ES EL MODELO? ¿QUÉ TAN BIEN, LA RECTA, SE AJUSTA A LOS VALORES?

El Coeficiente de determinación (R^2), es una medida de la bondad de ajuste del modelo que indica qué tan bien las variables independientes explican el comportamiento de la Var. dependiente. Es decir, en qué proporción, Y se encuentra explicada por los regresores.

COEFICIENTE DE DETERMINACIÓN:
$$R^2 = 1 - \frac{\sum_{i=1}^n (\hat{y}_i - y_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2}$$

$$0 \leq R^2 \leq 1.$$

Valores cercanos a 1 indica un mejor ajuste.



REGRESIÓN MULTIPLE

$$y_j = b_0 + b_1x_{1j} + b_2x_{2j} + \dots + b_kx_{kj} + u_j$$

Dos o más variables independientes influyen sobre una variable dependiente.

EJEMPLO

En la Universidad de la Ciudad de Bs.As, se quiere entender los factores que influyen en el aprendizaje de los alumnos que cursan la asignatura de Análisis de datos, para lo cual se toma al azar una muestra de las de notas de 15 en las materias de Algoritmos, Base de Datos y Programación:



REGRESIÓN MULTIPLE

Alumno	Análisis Datos	Algoritmos	B. de Datos	Programación
1	13	15	15	13
2	13	14	13	12
3	13	16	13	14
4	15	20	14	16
5	16	18	18	17
6	15	16	17	15
7	12	13	15	11
8	13	16	14	15
9	13	15	14	13
10	13	14	13	10
11	11	12	12	10
12	14	16	11	14
13	15	17	16	15
14	15	19	14	16
15	15	13	15	10

OBJETIVO:

Construir un modelo para determinar la relación que exista entre el aprendizaje de la asignatura de análisis de datos, conociendo las notas de las asignaturas Algoritmos, Base de Datos y Programación

$$Y = a + b_1x_1 + b_2x_2 + b_3x_3$$



REGRESIÓN MULTIPLE

	<i>Coefficientes</i>	<i>Error típico</i>	<i>Estadístico t</i>	<i>p-valor</i>	<i>Inferior 95%</i>	<i>Superior 95%</i>
Intercepción	2.551	2.369	1.077	0.305	-2.663	7.766
Algoritmos	0.583	0.267	2.186	0.051	-0.004	1.169
Base de Datos	0.373	0.144	2.589	0.025	0.056	0.691
Programación	-0.242	0.270	-0.893	0.391	-0.837	0.354

Por lo tanto podemos construir la ecuación de regresión que buscamos:

$$Y = 2.551 + 0.583x_1 + 0.373x_2 - 0.242x_3$$

<i>Estadísticas de la regresión</i>	
Coefficiente de correlación múltiple	0.83489314
Coefficiente de determinación R^2	0.69704656
R^2 ajustado	0.6144229
Error típico	0.86126471
Observaciones	15

El 69.70% del aprendizaje/rendimiento del Curso de Análisis de datos, puede ser explicado mediante las notas obtenidas por las asignaturas de Algoritmos, Base de Datos y Programación.

6-REDUCCIÓN DE DIMENSIONALIDAD





REDUCCIÓN DE DIMENSIONALIDAD. PCA

PCA → ANÁLISIS DE COMPONENTES PRINCIPALES

REALIDAD → MODELOS → INFINIDAD DE VARIABLES → QUEDARNOS CON LO QUE SEA RELEVANTE!

¿CÚANDO LO USAMOS?

- DATASET TIENE GRAN CANTIDAD DE VARIABLES (FEATURES)
- HAY UNA ALTA CORRELACIÓN ENTRE LAS VARIABLES
- ALTO COSTO COMPUTACIONAL

¿QUÉ ES LO QUE HACE?

REDUCE LA COMPLEJIDAD DEL PROBLEMA :

- SELECCIONA SOLO LAS VARIABLES RELEVANTES
- COMBINA ESAS VARIABLES EN NUEVAS QUE MANTENGAN LA INFO RELEVANTE



REDUCCIÓN DE DIMENSIONALIDAD. PCA

Conjunto de datos con indicadores de países europeos

	Area	GDP	Inflation	Life.expect	Military	Pop.growth	Unemployment
Austria	83871	41600	3.5	79.91	0.80	0.03	4.2
Belgium	30528	37800	3.5	79.65	1.30	0.06	7.2
Bulgaria	110879	13800	4.2	73.84	2.60	-0.80	9.6
Croatia	56594	18000	2.3	75.99	2.39	-0.09	17.7
Czech Republic	78867	27100	1.9	77.38	1.15	-0.13	8.5
Denmark	43094	37000	2.8	78.78	1.30	0.24	6.1
Estonia	45228	20400	5.0	73.58	2.00	-0.65	12.5
Finland	338145	36000	3.3	79.41	2.00	0.07	7.8



Centramos los datos (le restamos la media a cada valor)

	Area_centrada	GDP_centrada	Inflation_centrada	Life.expect_centrada	Military_centrada	Pop.growth_centrada	Unemployment_centrada
Austria	-82551.54	9739.286	0.15714286	1.7875	-0.806071429	-0.08714286	-5.7214286
Belgium	-135894.54	5939.286	0.15714286	1.5275	-0.306071429	-0.05714286	-2.7214286
Bulgaria	-55543.54	-18060.714	0.85714286	-4.2825	0.993928571	-0.91714286	-0.3214286
Croatia	-109828.54	-13860.714	-1.04285714	-2.1325	0.783928571	-0.20714286	7.7785714
Czech Republic	-87555.54	-4760.714	-1.44285714	-0.7425	-0.456071429	-0.24714286	-1.4214286
Denmark	-123328.54	5139.286	-0.54285714	0.6575	-0.306071429	0.12285714	-3.8214286
Estonia	-121194.54	-11460.714	1.65714286	-4.5425	0.393928571	-0.76714286	2.5785714

Con esto logramos centralizar las variables y que su media sea 0. Calculamos la matriz de correlaciones :



REDUCCIÓN DE DIMENSIONALIDAD. PCA

	Area_centrada	GDP_centrada	Inflation_centrada	Life.expect_centrada	
Area_centrada	1.00	-0.14	0.32	-0.02	
GDP_centrada	-0.14	1.00	-0.49	0.70	
Inflation_centrada	0.32	-0.49	1.00	-0.68	
Life.expect_centrada	-0.02	0.70	-0.68	1.00	
Military_centrada	0.10	-0.28	0.05	-0.06	
Pop.growth_centrada	-0.09	0.76	-0.48	0.77	
unemployment_centrada	0.03	-0.53	0.20	-0.25	
	Military_centrada	Pop.growth_centrada	unemployment_centrada		
Area_centrada	0.10	-0.09	0.03		
GDP_centrada	-0.28	0.76	-0.53		
Inflation_centrada	0.05	-0.48	0.20		
Life.expect_centrada	-0.06	0.77	-0.25		
Military_centrada	1.00	-0.28	0.29		
Pop.growth_centrada	-0.28	1.00	-0.17		
unemployment_centrada	0.29	-0.17	1.00		



OBTENEMOS LOS AUTOVALORES Y MATRIZ DE AUTOVECTORES QUE SIRVEN PARA CALCULAR EL NUEVO CONJUNTO TRANSFORMADO:



REDUCCIÓN DE DIMENSIONALIDAD. PCA

Autovalores obtenidos:

$$\lambda_1=3.22$$

$$\lambda_2=1.18$$

$$\lambda_3=1.06$$

$$\lambda_4=0.77$$

$$\lambda_5=0.46$$

$$\lambda_6=0.17$$

$$\lambda_7=0.12$$

	[,1]	[,2]	[,3]	[,4]	[,5]	[,6]	[,7]
[1,]	0.126	0.155	0.902	-0.043	-0.322	0.194	-0.063
[2,]	-0.500	0.130	0.087	0.087	0.396	0.625	0.413
[3,]	0.407	0.364	0.207	-0.155	0.690	-0.336	0.215
[4,]	-0.483	-0.268	0.243	-0.021	-0.106	-0.619	0.490
[5,]	0.186	-0.664	0.226	0.566	0.363	0.040	-0.140
[6,]	-0.475	-0.089	0.162	-0.394	0.349	-0.106	-0.672
[7,]	0.272	-0.553	-0.006	-0.700	0.017	0.250	0.259

Matriz de autovectores para la correlación



REDUCCIÓN DE DIMENSIONALIDAD. PCA

	PC1	PC2	PC3	PC4	PC5	PC6	PC7
Austria	-15273.601	-11526.096	-73613.86	4400.555	30437.850	-9930.557	9222.671
Belgium	-20093.798	-20290.185	-122059.81	6361.881	46109.767	-22653.171	11014.439
Bulgaria	2034.822	-10956.082	-51672.34	818.196	10734.056	-22060.973	-3961.352
Croatia	-6905.073	-18829.928	-100271.86	3512.032	29875.797	-29966.014	1195.498
Czech Republic	-8652.223	-14189.216	-79389.89	3351.779	26306.447	-19960.623	3549.011
Denmark	-18110.732	-18445.884	-110795.20	5752.769	41746.368	-20714.888	9891.399
Estonia	-9536.147	-20274.845	-110315.37	4212.842	34487.742	-30671.690	2901.239
Finland	19566.267	27155.644	155254.18	-7022.242	-53655.552	35899.919	-9108.942
Germany	20893.612	30355.430	172463.81	-7650.062	-58903.287	40873.902	-9430.897
Greece	-1560.686	-6071.502	-31570.68	994.514	8896.711	-10160.956	-122.713
Hungary	-3115.195	-12969.622	-67269.21	2088.775	18778.476	-21899.471	-440.787
Iceland	-11113.252	-9017.506	-56663.73	3270.463	22892.529	-8407.174	6573.196
Ireland	-16585.233	-13744.026	-85948.81	4908.291	34499.528	-13066.081	9750.854
Italy	17677.470	20734.840	121578.08	-5918.772	-43982.832	25320.976	-9060.637
Latvia	-5296.701	-17741.506	-93165.42	3066.486	26827.250	-29165.018	194.419
Lithuania	-6357.984	-17334.446	-92323.43	3233.945	27508.707	-27590.497	1101.232
Luxembourg	-45015.575	-19056.259	-143539.80	11287.398	72056.017	-1324.453	30450.155
Netherlands	-20807.896	-18036.320	-111758.68	6255.771	44225.373	-17892.367	12054.425
Norway	9056.429	27196.039	143830.45	-4888.411	-42148.204	43991.330	-1020.443
Poland	24261.503	21154.055	130914.00	-7305.353	-51713.286	21088.495	-14030.410
Portugal	-5134.821	-12623.464	-67783.66	2458.572	20585.140	-19708.220	1189.615
Slovakia	-10508.433	-19308.660	-106628.87	4300.253	34409.209	-28121.720	3859.869
Slovenia	-16884.128	-23052.534	-132093.68	6017.260	45847.070	-30264.534	7943.379
Spain	43388.994	52352.741	305612.87	-14701.836	-109680.189	64906.367	-21911.426
Sweden	31345.968	45149.800	256822.65	-11435.895	-87907.198	60593.419	-14232.564
Switzerland	-22093.163	-17752.142	-111781.53	6485.625	45299.467	-16381.400	13102.712
Ukraine	67414.612	64554.395	392142.02	-20940.895	-150516.848	69393.590	-37727.494
United Kingdom	7404.962	12567.279	70027.78	-2913.942	-23016.108	17871.808	-2946.449



REDUCCIÓN DE DIMENSIONALIDAD. PCA

CONCLUSIÓN

Importance of components:

	PC1	PC2	PC3	PC4	PC5	PC6	PC7
standard deviation	1.796	1.0896	1.0311	0.8777	0.67665	0.4107	0.35446
Proportion of Variance	0.461	0.1696	0.1519	0.1100	0.06541	0.0241	0.01795
Cumulative Proportion	0.461	0.6306	0.7825	0.8925	0.95795	0.9820	1.00000

Tabla 12. Salida de comando summary para el análisis de componentes principales.

Si quisiéramos perder la menor cantidad de información posible y agrupar hasta un 95% de variabilidad, nos quedaríamos con las primeras 5 componentes, en vez de las 7 variables originales, Si consideráramos que con un valor cercano a 90% estamos bien, podemos considerar solamente las primeras 4 componentes.



REDUCCIÓN DE DIMENSIONALIDAD. PCA

Dado que la matriz de covarianzas es cuadrada, podemos obtener sus Autovalores y los correspondientes Autovectores. Los primeros, ordenados de mayor a menor son los siguientes:

$\lambda_1 = 2.740712e+10$
 $\lambda_2 = 2.062455e+08$
 $\lambda_3 = 1.613000e+01$
 $\lambda_4 = 5.370000e+00$
 $\lambda_5 = 7.800000e-01$
 $\lambda_6 = 5.500000e-01$
 $\lambda_7 = 6.000000e-02$

La tabla 4 nos muestra los autovectores asociados:

	[,1]	[,2]	[,3]	[,4]	[,5]	[,6]	[,7]
[1,]	1.000	-0.012	0.000	0.000	0.000	0.000	0.000
[2,]	-0.012	-1.000	0.000	0.000	0.000	0.000	0.000
[3,]	0.000	0.000	0.041	-0.348	-0.932	0.091	0.036
[4,]	0.000	0.000	-0.178	0.916	-0.349	-0.020	0.084
[5,]	0.000	0.000	-0.039	0.052	0.071	0.988	-0.118
[6,]	0.000	0.000	-0.037	0.053	-0.071	-0.117	-0.988
[7,]	0.000	0.000	-0.982	-0.185	0.024	-0.027	0.028

Tabla 4. Matriz de Autovectores para la covarianza.



**CON ESTO OBTENEMOS EL
NUEVO CONJUNTO
TRANSFORMADO DE PCA**



VAMOS A COLAB!!!!



https://colab.research.google.com/drive/1RALT9IJ2Zt9uGFWNNuENko4u_kHiWGCH?authuser=3#scrollTo=EXr7oisPb8wp