

Introducción a la estadística



Marcelo Carballo Llosa

Maximiliano Vázquez

Fernando Raballo



Objetivo de la materia

Proporcionar las herramientas estadísticas básicas que le permitirán plantear, resolver e interpretar problemas estadísticos reales y familiarizarlo con el análisis estadístico



Objetivos Específicos

Proveer al estudiante los conocimientos mínimos que le permitan:

- Realizar un muestreo, diseñar un experimento sencillo y recolectar datos de manera apropiada.
- Analizar los datos obtenidos de manera descriptiva y formular una interpretación de los resultados.
- Aplicar las técnicas inferenciales más adecuadas al problema en cuestión e interpretar resultados.
- Interesar al estudiante en la forma en que distintos métodos estadísticos pueden emplearse para resolver problemas aplicados a su área.

Temario del capítulo

01. Introducción a la estadística

- Qué es la estadística
- Población y muestra
- Datos y tipos de datos
- Métodos estadísticos: Descriptiva e Inferencial

02. Tablas de Frecuencias y Gráficos

- Tablas de frecuencias
- Frecuencias Relativas y Acumuladas
- Introducción a los gráficos

03. Descripción numérica de los datos

- Medidas de tendencia central
- Medidas de variabilidad o dispersión
- Medidas de posición
- Muestreos y técnicas de muestreo
- Datos anómalos

Módulo 1

Introducción a la estadística



Marcelo Carballo Llosa
Maximiliano Vázquez
Fernando Raballo



¿Qué es la estadística





La estadística **es una ciencia, dentro de rama de las matemáticas a través de la cual se recolecta, analiza, describe y estudia una serie de datos** a fin de establecer mediciones y distribuciones que permitan comprender un fenómeno en particular.

La estadística se vale, en gran medida, de la **observación** para la recolección de **datos** que posteriormente serán analizados y comparados a fin de obtener un resultado.

Asimismo, la estadística se emplea para estudiar una población o muestra sobre el que se pretende obtener una información en particular, de esta manera se puede ofrecer una solución a un problema o ver cómo ha variado una situación específica.

Se trata de una ciencia que puede ser aplicada más allá de las ciencias exactas, ya que la estadística también es aplicada en diversos estudios en las áreas de las ciencias sociales, ciencias de la salud, economía, negocios y en diversos estudios de tipo gubernamental.

El objetivo de la estadística es tanto ofrecer un resultado numérico como exponer de qué manera se está desarrollando un fenómeno.

De allí que tras un **análisis estadístico** se pueda **comprender** un hecho, tomar **decisiones**, estudiar problemas sociales, ofrecer información y soluciones en determinados casos, deducir datos en relación a una población, entre otros.

Pasos de un Estudio Estadístico

El proceso estadístico es el conjunto de etapas o fases que deben completarse para realizar una investigación basada en información cuantitativa y obtener unos resultados fieles a la realidad estudiada. Esto es necesario, ya que si no realizamos estos pasos podemos obtener conclusiones erróneas y, por ende, tomar malas decisiones.


Todo estudio estadístico, suele iniciarse con el planteo del problema o necesidad a resolver. Acá es donde se define cual será el objeto de estudio y cómo serán abordada la problemática a resolver, los datos a consumir, y los análisis a desarrollar en las siguientes etapas.

Luego se procede a recopilar los datos pudiendo ser la recopilación completa de la información de cada uno de los objetos de estudio (ventas, personas, visitas, etc.) esto se lo suele conocer como Censo; o por medio un subconjunto de los integrantes del objeto de estudio (rating de televisión, estudio de mercado, análisis bioquímico, etc.)

Una vez esto, se procede al ordenamiento y primer abordaje de los datos. (Identificación de magnitudes, comparaciones preliminares, detección de anomalías, visualización de los datos).

Se realizan los planteos de las hipótesis que se quieren validar y se los contrasta contra los datos obtenidos.



Se analizan los resultados obtenidos y aplicando (o no, según se considere) los conocimientos previos sobre el dominio que pueda tener el investigador que esté llevando adelante el estudio, se obtienen las conclusiones finales que llevarán a tomar una decisión de concluir con el estudio o volver al inicio y redefinir alguno de los pasos realizados.





La estadística como parte de nuestro día a día.

- Tasa de robos en los últimos 6 meses.
- Porcentajes de goles por partido.
- Estatura promedio de los ingresantes a la escuela.
- Estimación de duración del tiempo de un viaje en auto.
- Alerta por una operación fraudulenta en una compra con una tarjeta de crédito.
- Estimación de cantidad de personal de seguridad para un evento.
- Promedio diario de reproducciones de un video en youtube



Así fueron los goles de Messi en el Barcelona
Más del 80% los consiguió con la pierna izquierda




La estadística en nuestro día a día...

<https://www.youtube.com/watch?v=HUThHJ6E3rY>



La estadística como parte de nuestro día a día (cont.)

Así, la estadística se encuentra presente en muchos momentos de nuestra vida sirviéndonos como fuente de información y por sobre todo, **conocimiento para ayudarnos a tomar (mejores) decisiones** y llevar adelante acciones.




Tipos de Estadística

- **Estadística descriptiva**

Es la rama de la estadística que recolecta, analiza y caracteriza un conjunto de datos con el objetivo de **describir** las **características** y comportamientos de este conjunto mediante medidas de **resumen**, tablas o gráficos utilizando la información de toda la población objetivo.

Veamos algunos ejemplos:

- *Estatuta promedio de los alumnos de la clase.*
- *Edad promedio de los habitantes de un país.*
- *Cantidad de policías en la provincia de Córdoba por género.*
- *Ventas totales de un supermercado.*




Datos
crudos

Estadística
descriptiva

Población y Muestra

Muchas veces obtener los datos de cada uno de los individuos del objetos de estudio nos resulta muy complicado, costoso, innecesario, o hasta puede llegar a ser imposible. Entonces para resolver esto, se procede a tomar una porción lo mas representativa posible de la totalidad y se lleva adelante el estudio estadístico logrando conclusiones sobre la totalidad de la población.



Población y Muestra



POBLACIÓN

Definición

- Conjunto de individuos, objetos o medidas de interés, que participan en el problema de estudio.



MUESTRA

Definición

- Parte de la población que se selecciona para obtener información cuyos resultados sean generalizables a la misma.

Tipos de Estadística

- **Estadística inferencial**

La Estadística inferencial o Inferencia estadística estudia cómo sacar conclusiones generales para toda la población a partir del estudio de una muestra, y el grado de fiabilidad o significación de los resultados obtenidos.

Veamos algunos ejemplos:

- *Índice de alcohol en sangre.*
- *Cantidad de autos ingresando a la capital federal.*
- *Tasa de mortalidad de una medicación.*
- *Rating de un programa de televisión.*
- *Estimación de resultados electorales.*
- *Índice de inflación.*



Tipo de Variables

¿Qué es un dato?

Un dato es la representación de una variable que puede ser cuantitativa o cualitativa que indica un valor que se le asigna a las cosas y se representa a través de una secuencia de símbolos, números o letras. Los datos describen hechos empíricos.

- *Altura de cada alumno – Peso de cada alumno – Ingreso monetario de cada empleado de una empresa*

Datos estadísticos:

Son los valores que se obtienen al llevar a cabo un estudio de tipo estadístico.

- *Altura promedio de cada alumno – Intervalo de confianza del peso de los alumnos – Estimación del ingreso monetario de un potencial empleado de la empresa*

Tipo de Variables



Cualitativa (o categórica):

Son las variables que pueden tomar como valores cualidades o categorías. se pueden clasificar según sigan una jerarquía o un orden determinado.

Ejemplos:

- Sexo (hombre, mujer)
- Salud (buena, regular, mala)



Son aquellas variables cuya única operación aritmética posible es el conteo.



Cuantitativas (o numérica):

Son aquellas variables o característica que se puede expresar con números.

Ejemplos:

- Edad (12,5; 24,3; 35;...)
- Altura (1.50; 1.68; 1.90)



Son aquellas variables que permiten operaciones aritméticas.

Clasificación de Variables

- Las variables se clasifican **según el atributo** que estén representando y las operaciones matemáticas que se puedan realizar con ellas.

Variables cualitativas

Nominal

Variables cualitativa cuyas categorías no siguen ningún orden.

- *Color (blanco, rojo, azul,...)*
- *Sexo (mujer, hombre)*
- *Estado civil (Casado, soltero, viudo, etc.)*

Ordinal

Son las variables categóricas que su significado representa un orden o jerarquía

- *Nota examen (Mal, Regular, Bueno, Muy Bueno, Excelente)*
- *Nivel económico (Baja, Medio, Alto)*
- *Medalla deportiva (Oro, plata, bronce)*

Variables cuantitativas

Discretas

La variable solo puede tomar valores en **número determinado de valores**. En cada intervalo de valores la variable solo puede tomar un valor.

- *Hijos por familia (0,1,2,...)*
- *Goles en un partido de fútbol (0,1,2,...)*
- *Número de transacciones de un cajero automático en una hora (140, 256, 340...)*

Continuas


Es aquella variable que puede tomar **cualquier valor** dentro de un intervalo real.

- *Peso en kg de un producto (0.8, 1.54, 1.91)*
- *Altura de los estudiantes (1.59, 1.78, 1.85)*
- *Deuda en pesos (154.90, 3509.78, 1234.65...)*

Clasificación de variables

- Variable independiente (causa):

Son las variables que se utilizan para describir o medir los factores que se supone son la causa, o que influyen en el problema.


$$y = f(x)$$

Variable dependiente Variable independiente

- Variable dependiente (consecuencia):

Es una variable cuyos valores dependen de los valores que tome otra variable.

Por ejemplo, “El tiempo que se tarda en llegar a un lugar dependerá de la velocidad y la distancia”.

↓
Variable
dependiente

↓ ↓
Variables
independientes

Clasificación de variables

La clasificación de las variables estadísticas va a depender también si la información obtenida es en base al total de la población o si se obtuvo a partir de una muestra de la población.

- **Parámetro:**

es una característica sobre una población.

“Se mide a cada alumno del curso y se obtiene la altura promedio de los alumnos del curso.”

- **Estimación:**

es una característica de una muestra.

“Se mide a cada alumno del curso y se obtiene la altura promedio (estimada) de los alumnos de la universidad”

Módulo 2

Tabla de Frecuencias y Gráficos



Marcelo Carballo Llosa
Maximiliano Vázquez
Fernando Raballo

Tablas de Frecuencia

PESO	x	f	f_r	F
49-53	51	3	0,1	3
53-57	55	6	0,2	9
57-61	59	8	0,26	17
61-65	63	9	0,3	26
65-69	67	4	0,13	30
		30	0,99	

Tablas de Frecuencia

Dentro de las ramas de la estadística, se encuentra la Estadística Descriptiva que tiene por objetivo fundamental la descripción numérica de un conjunto de datos. Es decir, se encarga de recoger, clasificar, representar y resumir los datos de muestras y extraer conclusiones acerca de las poblaciones.

Una vez que se define el objeto de estudio y el método de recolección de los datos se procede a la obtención de los datos. A los datos tal como se presentan se los denomina **Datos no Agrupados**. Sucede que si el número de observaciones es grande, resulta complejo poder analizarlos y extraer información de valor. Por lo tanto es necesario disponerlos de forma ordenada o agrupadas en clases de forma **resumida** para que puedan ser estudiados convenientemente.

La forma habitual de presentar los datos es a través de una **tabla de frecuencias**, o cuadro estadístico, en el cual nos permite ordenar los datos de manera que se consolidan los valores de una o más variables (cualitativa o cuantitativa) y se le asigna el valor de la cantidad de veces que estos fueron observados o registrados.

Tabla de Frecuencia

Se le llama distribución de frecuencias a la agrupación de datos **en categorías exhaustivas y mutuamente excluyentes** que indican el número de observaciones en cada clase o categoría y disponiéndolos en formato tabular.

Las formas de presentación pueden difieren según el tipo de variable en estudio.

Variable Estudio	Frecuencia Absoluta
Cat 1	# Obs Cat 1
Cat 2	# Obs Cat 2
Cat 3	# Obs Cat 3
...	...
Cat n	# Obs Cat n
Total	$\sum_{n=1}^n \# obs$

Variable de estudio: Es la variable por la cual se está realizando el análisis y se agrupa por cada valor o clase posible. Estos grupos o clases deben ser mutuamente excluyentes (una observación solo puede pertenecer a un único grupo)

Frecuencia Absoluta (Simple):

Cantidad de veces que se repite un valor de la variable.

Total:

Es la sumatoria del número observaciones de cada categoría.

Tabla de Frecuencias - Ejemplos

Cantidad de delitos por Tipo
Variable Cualitativa - Nominal

Tipo de delito	Frecuencia Absoluta
Homicidio	198
Hurto (sin violencia)	49,351
Lesiones	10,106
Robo (con violencia)	62,829

Cantidad de delitos por Barrio
Variable Cualitativa - Nominal

Barrio del Delito	Frecuencia Absoluta
Agronomía	489
Almagro	5079
Balvanera	9499
Barracas	3835
Belgrano	4172
Boca	1731
Boedo	1889
Caballito	5155
Chacarita	1543
Coghlan	493
Colegiales	1534
Constitución	3735
Flores	5749

Cantidad de alumnos por resultado de la evaluación
Variable Cualitativa - Ordinal

Resultado Evaluación	# de Alumnos
Malo	101,567
Regular	214,924
Bueno	791,805
Excelente	84,003
Sin Información	61,090
Total	1,253,389

Total de llamadas por Período
Variable Cualitativa - Ordinal

Período	Total de Llamados
ene	14,752
feb	9,885
mar	28,204
abr	14,389
may	9,039
jun	12,372
jul	8,789
ago	18,156
sep	13,774
oct	9,224
nov	5,911
dic	8,310
Total	152,805

Cantidad de detenciones históricas de las personas detenidas
Variable Cuantitativa - Discreta

# de Detenciones	Cantidad de Casos
0	697
1	700
2	380
3	279
4	246
5	146
Total	2,448

Rangos de Ingresos por Hogar
Variable Cuantitativa - Continua

Desde	Hasta	Hogares por decil
\$	\$	
900	13.500	26.181
13.500	18.700	25.903
18.700	24.000	25.773
24.000	29.000	25.630
29.000	35.000	25.843
35.000	42.000	25.827

Tablas de Frecuencias

Variables Cualitativas



x_i	f_i
0	6
1	7
2	6
3	4
4	1
5	1
	25

Construcción de una tabla de Frecuencia

Variables Categóricas

A continuación vamos a describir cómo se construye una tabla de Frecuencias para variables Categóricas utilizando un ejemplo práctico.

Caso de estudio:

Se quiere describir el comportamiento de los delitos sucedidos en los últimos 30 días en CABA.

Los datos que se van a utilizar para el estudio son las denuncias registradas.

id	Tipo Delito
1026060	Lesiones
1026065	Hurto (sin violencia)
1029674	Lesiones
1029677	Lesiones
1029700	Robo (con violencia)
1029709	Robo (con violencia)
993124	Robo (con violencia)
994036	Homicidio
1033230	Hurto (sin violencia)
1043622	Hurto (sin violencia)
1047175	Hurto (sin violencia)
988461	Robo (con violencia)
1053986	Hurto (sin violencia)
1054012	Hurto (sin violencia)
981559	Hurto (sin violencia)

Paso 1) Se parten de los casos recopilados y se procede a identificar cada una de las categorías existentes o grupos en que se quiere consolidar la información.

- Robo (con violencia)
- Hurto (sin violencia)
- Lesiones
- Homicidio

Construcción de una tabla de Frecuencia - Variables Categóricas

Paso 2) Se procede a realizar el conteo por cada una de las categorías definidas disponiéndose en una tabla ordenada.

Paso 3) Se obtiene el total de las observaciones sumalizando la frecuencia absoluta de cada una de las categorías de la variable de estudio.

id	Tipo Delito
1026060	Lesiones
1026065	Hurto (sin violencia)
1029674	Lesiones
1029677	Lesiones
1029700	Robo (con violencia)
1029709	Robo (con violencia)
993124	Robo (con violencia)
994036	Homicidio
1033230	Hurto (sin violencia)
1043622	Hurto (sin violencia)
1047175	Hurto (sin violencia)
988461	Robo (con violencia)
1053986	Hurto (sin violencia)
1054012	Hurto (sin violencia)
981559	Hurto (sin violencia)

Tipo Delito	Cantidad de Casos
Homicidio	1
Hurto (sin violencia)	7
Lesiones	3
Robo (con violencia)	4
Total	15

- **Variable de estudio:** Tipo Delito
- **Frecuencia Absoluta:** Cantidad de Casos

Construcción de una tabla de Frecuencia - Variables Categóricas

Frecuencia Relativa: Representa la relación entre el conjunto de elementos de una clase y el número total de observaciones.

$$Frecuencia\ Relativa = \frac{x_i}{\sum x_i}$$

Tipo Delito	Cantidad de Casos	Frecuencia Relativa		
Homicidio	1	1/15	0.07	7%
Hurto (sin violencia)	7	7/15	0.47	47%
Lesiones	3	3/15	0.20	20%
Robo (con violencia)	4	4/15	0.27	27%
Total	15			

- **Variable de estudio:** Tipo Delito
- **Frecuencia Absoluta:** Cantidad de Casos
- **Frecuencia Relativa:** Cantidad de casos registrados en la categoría sobre el total de casos.

Representación Gráfica

Los gráficos son una forma de presentación de los datos dispuestos de forma plástica (dibujos)

Una representación visual que se rige por dos principios:

Principio de reducción: consiste en el uso de primitivas gráficas (puntos, líneas, formas geométricas simples...) para la representación de elementos y sus relaciones, que revelan patrones y estructuras subyacentes, sin necesidad de visualizar los datos originales

Principio de uso de variables espaciales: posición, tamaño, forma, etc. para representar diferencias en los datos y revelar así los patrones y relaciones existentes más importantes

La visualización de datos es la presentación gráfica de información con dos propósitos

- I. Por un lado, la interpretación y construcción de significado a partir de los datos (es decir, el análisis)
- II. Por otro lado, la comunicación

• Es una herramienta muy potente para descubrir y comprender la lógica que se encuentra detrás de un conjunto de datos, así como para compartir esta interpretación con otras personas desde un punto de vista objetivo

"Una imagen vale mas que mil palabras."
-Napoleon Bonaparte


Gráficos para frecuencias absolutas

Para graficar las **frecuencias absolutas** de variables **cualitativas** se utilizan los gráficos de **barras o columnas**. En el cual sobre un eje se disponen cada uno de las categorías y sobre el otro eje se disponen los valores numéricos de la frecuencia de clase que puede tomar cada variable.


La altura / anchura de cada barra representa el total de casos registrados para esa categoría.

Tipo Delito	Cantidad de Casos
Homicidio	1
Hurto (sin violencia)	7
Lesiones	3
Robo (con violencia)	4
Total	15

Frecuencia Absoluta



Categorías de la Variable de Estudio



Categorías de la Variable de Estudio


Frecuencia Absoluta

Gráficos para frecuencias relativas

Para graficar las frecuencias relativas se utilizan los gráficos circulares o de torta. En el cual se divide el total del círculo (360°) sobre la cantidad de categorías posibles asignándole el tamaño según el valor de frecuencia correspondiente.

Tipo Delito	Cantidad de Casos	Frecuencia Relativa		
Homicidio	1	1/15	0.07	7%
Hurto (sin violencia)	7	7/15	0.47	47%
Lesiones	3	3/15	0.20	20%
Robo (con violencia)	4	4/15	0.27	27%
Total	15			

Participación por tipo de delito



* En caso de que las categorías posibles sean superior a 7 o los valores de frecuencias muy desparejos no se recomienda el uso de gráficos circulares por problemas de contaminación visual. Se puede reemplazar por gráficos de barra o columna.

Tablas de Frecuencias

Variables Cuantitativas



EDADES	X	f	f _r	F
13-15	14	4	0,2	4
15-17	16	9	0,45	13
17-19	18	3	0,15	16
19-21	20	3	0,15	19
21-23	22	1	0,5	20
		20	1	

Construcción de distribuciones de frecuencias: Datos Cuantitativos

El procedimiento para armar una tabla de frecuencias de Variables Cuantitativas es similar al de las variables Cualitativas. En el caso de variables discretas se dispondrán de forma ordenada cada valor posibles de la variable y luego se le asignará el valor del conteo de cuantas veces se repite tal valor. Y en el caso de las variable Continuas crearemos Clases de Equivalencia o Intervalos de Clase (veremos a continuación), los dispondremos ordenados y les asignaremos los valores de frecuencia.



En ciertas ocasiones también vamos a utilizar los Intervalos de Clase cuando trabajemos con **Variables Discretas**. Esto será cuando los valores posibles que pueda tomar la variable sean muchos (una regla nemotécnica es +15) que haga muy complejo la construcción de la tabla y con ello, el análisis. El procedimiento será exactamente igual al de las variables Continuas.

A diferencia de las tablas de frecuencias de **variables Cualitativas**, ahora vamos a poder realizar un ordenamiento y la acumulación de las frecuencias absolutas.

Construcción de una tabla de Frecuencia

Variables Discretas

El proceso para la construcción de una tabla de frecuencias de variables Cuantitativas Discretas es similar al de las variables Cualitativas agregándose en este caso la posibilidad de construir dos nuevos estadísticos que son los de **Frecuencias Absolutas Acumuladas** y **Frecuencia Relativa Acumulada**.



Frecuencia Absoluta Acumulada: es la cantidad de observaciones (casos) con valor menor o igual a cierto valor dado de la variable. Esta se obtiene sumando, a la frecuencia absoluta simple correspondiente a un valor de la variable, las frecuencias absolutas simples correspondientes a todos los valores anteriores.



Frecuencia Relativa Acumulada: es la proporción de observaciones acumuladas hasta el valor de la variable actual sobre el total de observaciones. Se lo suele mostrar en valores porcentuales indicando que porcentaje del total se presenta en valores de la variable igual o menores al actual.

Construcción de una tabla de Frecuencia (Cont.)

Variables Discretas

Pasos para construir una tabla de frecuencia de Variables Cuantitativas Discretas

Base: Personas trasladadas con COVID

Paso 1) Se parten de los casos recopilados y se procede a identificar cada uno de los valores posibles (Recorrido de la variable).

Nº Casos: 0,1,2,3,4,5

Paso 2) Se procede a realizar el conteo por cada una de los valores posibles definidos obteniendo la Frecuencia Absoluta.

Paso 3) Se calcula la Frecuencia Relativa dividiendo la frecuencia absoluta de la variable sobre el total de observaciones.

REGISTRO TRASLADOS CASOS CON COVID

FECHA	Nº Casos	FECHA	Nº Casos	FECHA	Nº Casos
1/7/2020	2	11/7/2020	1	21/7/2020	3
2/7/2020	1	12/7/2020	1	22/7/2020	2
3/7/2020	0	13/7/2020	0	23/7/2020	1
4/7/2020	5	14/7/2020	2	24/7/2020	2
5/7/2020	1	15/7/2020	1	25/7/2020	0
6/7/2020	1	16/7/2020	1	26/7/2020	0
7/7/2020	1	17/7/2020	4	27/7/2020	3
8/7/2020	5	18/7/2020	1	28/7/2020	0
9/7/2020	1	19/7/2020	5	29/7/2020	1
10/7/2020	1	20/7/2020	3	30/7/2020	1

Construcción de una tabla de Frecuencia (Cont.)

Variables Discretas

Pasos para construir una tabla de frecuencia de Variables Cuantitativas Discretas

Paso 1) Se parten de los casos recopilados y se procede a identificar cada uno de los valores posibles (Recorrido de la variable).

Nº Casos: 0,1,2,3,4,5

Paso 2) Se procede a realizar el conteo por cada una de los valores posibles definidos obteniendo la Frecuencia Absoluta.

Paso 3) Se calcula la Frecuencia Relativa dividiendo la frecuencia absoluta de la variable sobre el total de observaciones.

Tabla de Frecuencias Número de Traslados de Casos con Covid

Nº Casos	Cantidad de Casos	Frecuencia Relativa Casos
0	5	16.67%
1	14	46.67%
2	4	13.33%
3	3	10.00%
4	1	3.33%
5	3	10.00%
Total	30	100.00%

REGISTRO TRASLADOS CASOS CON COVID

FECHA	Nº Casos	FECHA	Nº Casos	FECHA	Nº Casos
1/7/2020	2	11/7/2020	1	21/7/2020	3
2/7/2020	1	12/7/2020	1	22/7/2020	2
3/7/2020	0	13/7/2020	0	23/7/2020	1
4/7/2020	5	14/7/2020	2	24/7/2020	2
5/7/2020	1	15/7/2020	1	25/7/2020	0
6/7/2020	1	16/7/2020	1	26/7/2020	0
7/7/2020	1	17/7/2020	4	27/7/2020	3
8/7/2020	5	18/7/2020	1	28/7/2020	0
9/7/2020	1	19/7/2020	5	29/7/2020	1
10/7/2020	1	20/7/2020	3	30/7/2020	1

Construcción de una tabla de Frecuencia (Cont.)

Variables Discretas

Pasos para construir una tabla de frecuencia de Variables Cuantitativas Discretas

Frecuencias Absoluta Acumuladas y Frecuencias Relativas Acumuladas

Paso 4) Construir la **Frecuencia Absoluta Acumulada** mediante la suma de todas las frecuencias absolutas correspondiente al valor de la variable y todas las frecuencias absolutas anteriores.

Paso 5) Construir la **Frecuencia Relativa Acumulada**, dividiendo la Frecuencia Absoluta Acumulada sobre el total de Observaciones

FECHA	Nº Casos	FECHA	Nº Casos	FECHA	Nº Casos
1/7/2020	2	11/7/2020	1	21/7/2020	3
2/7/2020	1	12/7/2020	1	22/7/2020	2
3/7/2020	0	13/7/2020	0	23/7/2020	1
4/7/2020	5	14/7/2020	2	24/7/2020	2
5/7/2020	1	15/7/2020	1	25/7/2020	0
6/7/2020	1	16/7/2020	1	26/7/2020	0
7/7/2020	1	17/7/2020	4	27/7/2020	3
8/7/2020	5	18/7/2020	1	28/7/2020	0
9/7/2020	1	19/7/2020	5	29/7/2020	1
10/7/2020	1	20/7/2020	3	30/7/2020	1

N.º Casos	Cantidad de Casos	Frecuencia Relativa Casos	Frecuencia Absoluta Acumulada (4)		Frecuencia Relativa Acumulada (5)	
0	5	16.67%	5	5	5 / 30	16.7%
1	14	46.67%	5+ 14	19	19 / 30	63.3%
2	4	13.33%	5+ 14+ 4	23	23 / 30	76.7%
3	3	10.00%	5+ 14+ 4+ 3	26	26 / 30	86.7%
4	1	3.33%	5+ 14+ 4+ 3+ 1	27	27 / 30	90.0%
5	3	10.00%	5+ 14+ 4+ 3+ 1+ 3	30	30 / 30	100.0%
Total	30	100.00%				



Cómo construir una tabla de frecuencias para una variable Discreta
<https://www.youtube.com/watch?v=cyXenZebGz4&t=13s>

Construcción de una tabla de Frecuencia (Cont.)

Variables Discretas

Pasos para construir una tabla de frecuencia de Variables Cuantitativas Discretas

Frecuencias Absoluta Acumuladas y Frecuencias Relativas Acumuladas

N.º Casos	Cantidad de Casos	Frecuencia Relativa Casos	Frecuencia Absoluta Acumulada (4)	Frecuencia Relativa Acumulada (5)
0	5	16.67%	5	5 / 30
1	14	46.67%	5 + 14	19 / 30
2	4	13.33%	5 + 14 + 4	23 / 30
3	3	10.00%	5 + 14 + 4 + 3	26 / 30
4	1	3.33%	5 + 14 + 4 + 3 + 1	27 / 30
5	3	10.00%	5 + 14 + 4 + 3 + 1 + 3	30 / 30
Total	30	100.00%		



La frecuencia acumulada del último valor debe ser igual al total de observaciones



La frecuencia relativa acumulada del último valor debe ser igual a 100%

REGISTRO TRASLADOS CASOS CON COVID


FECHA	Nº Casos	FECHA	Nº Casos	FECHA	Nº Casos
1/7/2020	2	11/7/2020	1	21/7/2020	3
2/7/2020	1	12/7/2020	1	22/7/2020	2
3/7/2020	0	13/7/2020	0	23/7/2020	1
4/7/2020	5	14/7/2020	2	24/7/2020	2
5/7/2020	1	15/7/2020	1	25/7/2020	0
6/7/2020	1	16/7/2020	1	26/7/2020	0
7/7/2020	1	17/7/2020	4	27/7/2020	3
8/7/2020	5	18/7/2020	1	28/7/2020	0
9/7/2020	1	19/7/2020	5	29/7/2020	1
10/7/2020	1	20/7/2020	3	30/7/2020	1

Gráficos para frecuencias acumuladas absolutas y relativas


Al igual que en las variables Cualitativas, se puede graficar las Frecuencias Absolutas y Relativas utilizando gráficos de Barras o Columnas y Circulares o Tortas respectivamente.

Adicionalmente se suman las de Frecuencias Absolutas y Relativas Acumuladas que se los puede graficar mediante un **gráfico de barras o columnas**.

Cantidad de Pasientes Traslados con Covid



Participación Acumulada de Casos con Traslados por Covid



¿Porqué no se podría utilizar el gráfico circular en frecuencias acumuladas?

Construcción de una tabla de Frecuencia Variables Continuas

Tal como definimos, una de las características de las Variables Cuantitativas Continuas es que, dado un intervalo de números reales, cualquiera de ellos puede ser un valor de la variable lo que hace que sea imposible realizar un listado de cada valor posible para construir la tabla de frecuencias. Entonces, para un adecuado análisis estadístico del comportamiento de una variable continua, es necesario agrupar a los valores individuales de ella en **Clases de Equivalencia o Intervalos de Clase**.

Pasos



Construcción de una tabla de Frecuencia Variables Continuas

Pasos para construir una tabla de frecuencia de Variables Cuantitativas Discretas

Base: Salarios Empleados 2019

Observaciones: 25

243,149	239,470	275,090	256,657	239,470
267,914	204,017	249,973	239,470	275,090
249,662	249,662	245,812	224,517	249,973
231,168	217,520	192,563	231,168	249,973
249,973	226,866	275,090	224,517	204,017

Paso 1) Calcular el número de clases H

Existen dos formas equivalentes:

En el ejemplo:

$$H = 2^5 = 32 \geq 25$$

Intervalos de Clase
(H) = 5

$$H = \text{ent} \left[1 + \frac{\ln(25)}{\ln(2)} \right] = 5,6438 \dots = 5$$

1

$$2^H \geq n$$

Buscar el menor número H (entero), de manera que 2^H sea mayor que el número de observaciones (N)

2

$$H = \text{ent} \left[1 + \frac{\ln(n)}{\ln(2)} \right]$$

Operando algebraicamente, lo obtenemos mediante el logaritmo del número de observaciones y nos quedamos con el número entero

Construcción de una tabla de Frecuencia Variables Continuas

Pasos para construir una tabla de frecuencia de Variables Cuantitativas Discretas

Base: Salarios Empleados 2019

Observaciones: 25

Intervalos de clase (H)= 5

243,149	239,470	275,090	256,657	239,470
267,914	204,017	249,973	239,470	275,090
249,662	249,662	245,812	224,517	249,973
231,168	217,520	192,563	231,168	249,973
249,973	226,866	275,090	224,517	204,017

Paso 2) Calculamos la amplitud de cada intervalo de clase:

1. Obtenemos la Amplitud Total Observada, la diferencia entre el valor máximo y el valor mínimo registrado.
2. Calculamos la amplitud de cada intervalo, dividiendo la Amplitud Total Observada sobre la cantidad de Intervalos (H).

En la práctica se suele redondear el resultado para arriba.

1

$$A = \text{Val Max} - \text{Val Min}$$

2

$$a = \frac{A}{H}$$

En el ejemplo:

$$A = 275,090 - 192,563 = 82,527$$

$$a = \frac{82,527}{5} = 16,505.38 = 16,600$$

Construcción de una tabla de Frecuencia Variables Continuas

Pasos para construir una tabla de frecuencia de Variables Cuantitativas Discretas

Base: Salarios Empleados 2019

Observaciones: 25

Intervalos de clase = 5

Amplitud de clase = 16,600


243,149	239,470	275,090	256,657	239,470
267,914	204,017	249,973	239,470	275,090
249,662	249,662	245,812	224,517	249,973
231,168	217,520	192,563	231,168	249,973
249,973	226,866	275,090	224,517	204,017

Paso 3) Se calculan los Intervalos. Recordar que deben ser **exhaustivos y excluyentes**:

1. Del mínimo valor identificado, se lo "redondea" para abajo en un múltiplo de 10 o 100
2. Al valor mínimo redondeado se le suma la amplitud de clase definida

Lim Inferior	Lim Superior
[192,500	209,100)
[209,100	225,700)
[225,700	242,300)
[242,300	258,900)
[258,900	275,500)

En el ejemplo:



[Li;LS) : Se suele utilizar el Intervalo Cerrado en el Límite Inferior e Intervalo Abierto en el Límite Superior

Construcción de una tabla de Frecuencia Variables Continuas

Pasos para construir una tabla de frecuencia de Variables Cuantitativas Discretas

Base: Salarios Empleados 2019

Observaciones: 25

Intervalos de clase = 5

Amplitud de clase = 16,600

243,149	239,470	275,090	256,657	239,470
267,914	204,017	249,973	239,470	275,090
249,662	249,662	245,812	224,517	249,973
231,168	217,520	192,563	231,168	249,973
249,973	226,866	275,090	224,517	204,017

Paso 4) Se procede a calcular las Frecuencias Absolutas, Acumuladas y Relativas.



En el ejemplo:

Lim Inferior	Lim Superior	Frecuencia de Clase	Frecuencia Relativa	Frecuencia Acumulada	Frecuencia Relativa Acumulada
[192500	209100)	3	12%	3	12%
[209100	225700)	3	12%	6	24%
[225700	242300)	6	24%	12	48%
[242300	258900)	9	36%	21	84%
[258900	275500)	4	16%	25	100%
Total		25			

Gráficos para distribuciones Continuas

Al igual que en las variables Discretas, se puede graficar las Frecuencias Absolutas, Acumuladas y Relativas. En lugar de un gráfico de columnas, se utilizará un Histograma para las Frecuencias Absolutas; y para las Frecuencias Acumuladas se utilizará una Ojiva (o gráfico de línea).

Esta diferencia se debe a que es una variable que es continua a lo largo del recorrido de la variable en lugar de ser valores discretos (saltos entre valores).



Unidad 3.1

Descripción de datos.

Medidas Numéricas

Marcelo Carballo Llosa
Maximiliano Vázquez
Fernando Raballo



Medidas numéricas. Introducción


Anteriormente, vimos que para llevar adelante el proceso de análisis de un fenómeno debíamos recopilar las observaciones; las cuales podían ser tomadas del total de la población que queríamos estudiar o sobre una muestra.

Una vez con los datos, generalmente desorganizados, procedíamos a construir una tabla de frecuencias la cual nos permitía ordenar, estructurar y realizar las primeras cuantificaciones mediante las frecuencias simples, absolutas, relativas y totalizaciones.

Las formas de agruparlos y las métricas que se podían construir dependían del tipo de variable en estudio ya que para las variables cualitativas solamente podríamos construir las frecuencias absolutas y relativas; mientras que para las cuantitativas adicionalmente podríamos construir las frecuencias acumuladas absolutas y acumuladas relativas.

Vimos que otra forma importante de abordar el análisis de un fenómeno es mediante las representaciones visuales o gráficos de los datos permitiéndonos comprender de forma rápida como era el comportamiento de la variable en estudio.

Medidas de posición o tendencia central



Medidas de posición o tendencia central


El objetivo de todo análisis estadístico es poder caracterizar el comportamiento de un fenómeno de forma resumida mediante parámetros o estadísticos que permitan describir o representar el comportamiento de la totalidad de la población que se esté estudiando.

Se llaman **medidas de posición o tendencia central** de la variable X (variable en estudio), a **aquellos valores destacados** con los cuales es posible **representar a la totalidad de los valores** de la variable.

O en otras palabras, las medidas de tendencia central son medidas estadísticas que pretenden **resumir en un solo valor a un conjunto de valores**. Representan un centro en torno al cual se encuentra ubicado el conjunto de los datos.

Las medidas de tendencia central más utilizadas son:

- **Media aritmética,**
- **Mediana,**
- **Moda.**



Media, mediana y moda en datos agrupados
<https://www.youtube.com/watch?v=5bZXpfxwHqk>

Medida de tendencia central: Media Aritmética o Promedio

Se define a la media aritmética de la variable X, como el número que resulta de sumar todos los valores observados y dividirlo por el número total de observaciones. En otras palabras, buscar cual sería el valor si todas las observaciones fueran iguales.

Esta medida solo puede ser realizada sobre Variables Cuantitativas ya que son las únicas que admiten operaciones algebraicas.



Es una medida sensible a valores extremos o también definida como no robusta.

Media =
$$\bar{x} = \frac{\sum x_i}{n}$$

$\sum x_i$ = Sumatoria de todos los valores observados


n = Número de observaciones

Si los datos están agrupados en frecuencias =

$$\bar{x} = \frac{\sum x_i * f_i}{n}$$

x_i = Valor de variable que representa a la clase o punto medio del intervalo de clase

f_i = Cantidad de observaciones (frecuencia absoluta)



Medida de tendencia central: Media o Promedio

Ejemplo 1: Calculo de la media para variables Cuantitativas discretas:

Datos
No agrupados

FECHA	Nº Casos
1/7/2020	2
2/7/2020	1
3/7/2020	0
4/7/2020	5
5/7/2020	1
6/7/2020	1
7/7/2020	1
8/7/2020	5
9/7/2020	1
10/7/2020	1

$$\bar{x} = \frac{2+1+0+5+1+1+1+5+1+1}{10} = \frac{18}{10} = 1,8$$

Media


$$\bar{x} = \frac{\sum x_i}{n}$$

$$\bar{x} = \frac{\sum x_i * f_i}{n}$$

Datos en tabla
de frecuencia

	Frecuencia Absoluta
0	1
1	6
2	1
5	2
Total general	10

$$\bar{x} = \frac{0*1+6*1+1*2+2*5}{10} = \frac{18}{10} = 1,8$$



Medida de tendencia central: Media o Promedio

Ejemplo 2: Cálculo de la media para variables Cuantitativas discretas.

Datos
No agrupados

FECHA	Nº Casos
1/7/2020	2
2/7/2020	1
3/7/2020	0
4/7/2020	5
5/7/2020	1
6/7/2020	1
7/7/2020	1
8/7/2020	5
9/7/2020	1
10/7/2020	1
11/7/2020	10


$$\bar{x} = \frac{2+1+0+5+1+1+1+5+1+1+3}{11} = \frac{28}{11} = 2,54$$

Media

$$\bar{x} = \frac{\sum x_i}{n}$$

$$\bar{x} = \frac{\sum x_i * f_i}{n}$$

La media es una **variable Sensible a valores extremos** o poco robusta, ante una nueva observación con un valor extremo, el resultado cambia significativamente.



Medida de tendencia central: Mediana

Se define a la mediana de la variable X , $Me(X)$, al valor que supera, y es superado por, a lo sumo, igual cantidad de observaciones. Es el lugar o punto central de un conjunto de observaciones. O sea, es el valor que deja la misma cantidad de observaciones a un lado que a otro.

Para calcular la mediana es importante que los datos estén ordenados de mayor a menor, o al contrario de menor a mayor. Esto es, que tengan un orden.

*Se puede calcular para **Variables Cuantitativas** tanto **Discretas** cómo **Continuas**, y también, para variables **Cualitativas Ordinales**, ya que es necesario que se ordenen las observaciones y se busque el valor que acumula al menos la mitad del total de observaciones, o sea, el 50%.*



*Al contrario que la media que puede estar desplazada hacia un lado o a otro, según la distribución, la mediana siempre se sitúa en el centro de esta. O sea, **es una medida Robusta a valores extremos**.*

Medida de tendencia central: Mediana

Para obtener la mediana lo que se debe hacer es:

- 1) Ordenar las observaciones de forma ascendente o descendente
- 2) Obtener el Orden Mediano que es la posición que ocupa el valor de la mediana entre las observaciones

$$OME = \frac{n + 1}{2}$$

- 3) Identificar el valor de la mediana.

- Cuando n es impar: es el valor del OMe
- Cuando n es par: es el valor medio entre las dos observaciones contiguas

FECHA	Nº Casos
1/7/2020	2
2/7/2020	1
3/7/2020	0
4/7/2020	5
5/7/2020	1
6/7/2020	1
7/7/2020	1
8/7/2020	5
9/7/2020	1
10/7/2020	1
11/7/2020	10

1) Ordenar las observaciones



Orden	FECHA	Nº Casos
1	3/7/2020	0
2	2/7/2020	1
3	5/7/2020	1
4	6/7/2020	1
5	7/7/2020	1
6	9/7/2020	1
7	10/7/2020	1
8	1/7/2020	2
9	4/7/2020	5
10	8/7/2020	5
11	11/7/2020	10

2) Obtener OMe



$$OME = \frac{11+1}{2} = 6^\circ$$

3) Identificar Mediana



Orden	FECHA	Nº Casos
1	3/7/2020	0
2	2/7/2020	1
3	5/7/2020	1
4	6/7/2020	1
5	7/7/2020	1
6	9/7/2020	1
7	10/7/2020	1
8	1/7/2020	2
9	4/7/2020	5
10	8/7/2020	5
11	11/7/2020	10

$$ME = 1$$

Medida de tendencia central: Mediana

Para obtener la mediana lo que se debe hacer es:

- 1) Ordenar las observaciones de forma ascendente o descendente
- 2) Obtener el Orden Mediano que es la posición que ocupa el valor de la mediana entre las observaciones

$$OME = \frac{n + 1}{2}$$

- 3) Identificar el valor de la mediana.

FECHA	Nº Casos
1/7/2020	2
2/7/2020	1
3/7/2020	0
4/7/2020	5
5/7/2020	1
6/7/2020	1
7/7/2020	1
8/7/2020	5
9/7/2020	3
10/7/2020	4

1) Ordenar las observaciones



Orden	FECHA	Nº Casos
1	3/7/2020	0
2	2/7/2020	1
3	5/7/2020	1
4	6/7/2020	1
5	7/7/2020	1
6	1/7/2020	2
7	9/7/2020	3
8	10/7/2020	4
9	4/7/2020	5
10	8/7/2020	5

2) Obtener OMe




$$OME = \frac{10+1}{2} = 5,5^\circ$$

3) Identificar Mediana



Orden	FECHA	Nº Casos
1	3/7/2020	0
2	2/7/2020	1
3	5/7/2020	1
4	6/7/2020	1
5	7/7/2020	1
6	1/7/2020	2
7	9/7/2020	3
8	10/7/2020	4
9	4/7/2020	5
10	8/7/2020	5



$$ME = \frac{1+2}{2} = 1,5$$

Medida de tendencia central: MODA o MODO

Se define a la **Moda** como el valor de la variable que más se repite (que presenta mayor frecuencia absoluta) y se la representa por el símbolo M_0 .

Al depender sólo de las frecuencias, puede calcularse para variables cualitativas y cuantitativas. Es por ello el parámetro más utilizado cuando al resumir una población no es posible realizar otros cálculos.

- Si en un grupo hay dos o varias puntuaciones con la misma frecuencia y esa frecuencia es la máxima, entonces la distribución es bimodal (en caso de que sean 2 valores) o multimodal (en caso de que existan mas de 2), es decir, tiene varias modas.
- Cuando todas las puntuaciones de un grupo tienen la misma frecuencia, no hay moda.

Tipo Delito	Cantidad de Casos
Homicidio	1
Hurto (sin violencia)	7
Lesiones	3
Robo (con violencia)	4
Total	15



MODA = M_0 = Hurto



Medida de tendencia central: MODA o MODO

Tanto para las variables **Cualitativas** como las **Cuantitativas Discretas**, la determinación de la Moda se puede determinar mediante la sola inspección de la columna de las frecuencias absoluta, siendo la clase o valor con mayor cantidad de observaciones.

Nº Casos	Cantidad de Casos	Frecuencia Relativa Casos
0	5	16.67%
1	14	46.67%
2	4	13.33%
3	3	10.00%
4	1	3.33%
5	3	10.00%
Total	30	100.00%

MODA = $M_0=1$

En el caso de las variables **Cuantitativas Continuas**, dado que los valores se encuentran agrupados en intervalos de clase, entonces, el intervalo de mayor frecuencia, si existe, se lo llama Intervalo Modal.

Lim Inferior	Lim Superior	Frecuencia de Clase
[192500	209100)	3
[209100	225700)	3
[225700	242300)	6
[242300	258900)	9
[258900	275500)	4
Total		25

Intervalo Modal = $M_0=(242.300 - 258.900)$

Unidad 3.2

Descripción de
datos.

Medidas de
Dispersión



Marcelo Carballo Llosa
Maximiliano Vázquez



Medidas de dispersión. Introducción

En el capítulo anterior, vimos que porque es necesario construir medidas de resumen. Entendimos que son aquellas que buscan caracterizar de forma resumida el comportamiento de la variable de estudio.

Entendimos que existen 3 medidas principales para describir como se comporta “típicamente” la variable y es a través de la Media o Promedia, Mediana y la Moda.

Media Aritmética, es el valor que resulta de dividir la suma de todas las observaciones sobre el número de observaciones. Y entendimos que la media es una medida no robusta, sensible a valores extremos.

Comprendimos el significado de la **Mediana**, que es el punto central de la distribución de la variable. Donde se acumula al menos la mitad de las observaciones, y que esta sí es una medida robusta o insensible a valores extremos.

Y por último trabajamos el concepto de la Moda, para identificar cual es el valor que mas se repite entre las observaciones. Siendo esta métrica una medida muy utilizada en variables cualitativas dado que no se puede construir las otras dos.

Medidas de Dispersión

A las medidas de Tendencia Central se las puede considerar como “representantes” de la totalidad de los valores observados de una variable. Estas medidas serán “buenos representantes” si los valores observados son homogéneos (similares); esto quiere decir que si no hay “demasiada” diferencia o variación entre cada uno de ellos y alguna medida en particular, entonces la medida en cuestión será representativa.

Las medidas de variabilidad o dispersión son aquellas que permiten estudiar, cómo se Desvían, en su conjunto, los valores observados de una variable, con respecto a alguna Medida de Tendencia Central.



Una medida pequeña de dispersión indica que los datos se acumulan con proximidad alrededor de la medida de tendencia central. Entonces, la media se considera representativa de los datos. Por el contrario, una medida grande de dispersión indica que la medida no es confiable.



Medidas de dispersión

<https://www.youtube.com/watch?v=2it1aEsA0Yk>


Rango

Representa la diferencia entre los valores máximo y mínimo de un conjunto de datos.

$$\text{Rango} = \text{Valor Máximo} - \text{Valor Mínimo}$$

Ejemplo:

En $\{4, 6, 9, 3, 7\}$ el menor valor es 3, y el mayor es 9, entonces el rango es $9-3$ igual a 6.




Varianza

Aunque el Rango mide la dispersión de los datos, ésta solo tiene en cuenta dos de los valores de los datos, el máximo y el mínimo.

Necesitamos una medida que considere cada uno de los valores de los datos; una medida que promedie la distancia total entre cada observación y la media.

Dado que esta distancia sería negativa en los casos menores que la media, y la distancia no es negativa!!!, entonces para resolver este inconveniente, debemos elevar al cuadrado cada una de las diferencias entre la observación y la media.

Y lo que buscamos es: *el promedio del desvío de las observaciones al cuadrado.*



Varianza Poblacional

$$\sigma^2 = \frac{\sum_{i=1}^N (x_i - \bar{X})^2}{N}$$

Varianza Muestral

$$s^2 = \frac{\sum_{i=1}^n (x_i - \bar{x})^2}{n-1}$$

Varianza

La **varianza** (S^2) mide la **dispersión** de los datos de una muestra ($X_1, X_2, \dots, X_N$) respecto a la media ($\bar{x}$), calculando la media de los cuadrados de las distancias de todos los datos.

Al elevar las diferencias al cuadrado se garantiza que las diferencias absolutas respecto a la media no se anulan entre sí. Además, resaltan los valores alejados.

Varianza Poblacional

$$\sigma^2 = \frac{\sum_{i=1}^N (x_i - \bar{X})^2}{N}$$

- X → Variable
- x_i → Observación número i de la variable X .

Varianza Muestral

$$S^2 = \frac{\sum_{i=1}^n (x_i - \bar{x})^2}{n-1}$$

- N → Número de observaciones.
- $\bar{x}$ → Es la media de la variable X .

Varianza (cont.)

Pasos para calcular la varianza de la siguiente muestra:

Observaciones $y = \{1, 3, 6, 10\}$ Media $\bar{X} = 5$

$$\text{Var}(X) = \frac{(x_1 - \bar{X})^2 + (x_2 - \bar{X})^2 + \dots + (x_n - \bar{X})^2}{n-1}$$

$$\text{Var } y = \frac{(1-5)^2 + (3-5)^2 + (6-5)^2 + (10-5)^2}{4-1}$$

$$\text{Var } y = \frac{(-4)^2 + (-2)^2 + (1)^2 + (5)^2}{3}$$

$$S^2 = 15,33$$

$$\text{Var } y = \frac{16 + 4 + 1 + 25}{3} = \frac{46}{3} = 15,3333$$

Varianza (cont.)

Ejercicio: Calcular la media y varianza de las observaciones que se obtuvieron de las edades de todos los detenidos en un operativo

Edad	19	24	30	45	23	51	39	44	26	23
------	----	----	----	----	----	----	----	----	----	----

Varianza (cont.)

Ejercicio: Calcular la media y varianza de las observaciones que se obtuvieron de las edades de todos los detenidos en un operativo

Edad	19	24	30	45	23	51	39	44	26	23
------	----	----	----	----	----	----	----	----	----	----

$$Var(X) = \frac{(x_1 - \bar{X})^2 + (x_2 - \bar{X})^2 + \dots + (x_n - \bar{X})^2}{n}$$

Obs	Edad	$(x_i - \bar{x})^2$	$(x_i - \bar{x})^2$
1	19	$(19-32,4)^2$	179,56
2	24	$(24-32,4)^2$	70,56
3	30	$(30-32,4)^2$	5,76
4	45	$(45-32,4)^2$	158,76
5	23	$(23-32,4)^2$	88,36
6	51	$(51-32,4)^2$	345,96
7	39	$(39-32,4)^2$	43,56
8	44	$(44-32,4)^2$	134,56
9	26	$(26-32,4)^2$	40,96
10	23	$(23-32,4)^2$	88,36
	324		1156,4

$$n = 10 \quad \bar{x} = 32,4$$

$$s^2 = \frac{1156,4}{10} = 115,64$$

Desvío estándar

Dado que el valor numérico de la **varianza** de la variable X queda expresado en otra dimensión, el cuadrado de la magnitud de la variable, y esto hace que su interpretación sea dificultosa, es necesario contar con una medida de variabilidad cuya magnitud esté en la misma dimensión que la de la variable.

*El **Desvío Estándar (Típico)** de la variable X, $S(X)$, es la raíz cuadrada de la **Varianza***

Desvío Estándar Poblacional

$$S = \sqrt{\frac{\sum_i (X_i - \bar{X})^2}{n}}$$

- X → Variable
- X_i → Observación número i de la variable X.

Desvío Estándar Muestral

$$S = \sqrt{\frac{\sum (X_i - \bar{X})^2}{n-1}}$$

- N → Número de observaciones.
- $\bar{X}$ → Es la media de la variable X.

Desvío estándar (cont.)

El **Desvío Estándar (Típico)**, es una medida de **variabilidad absoluta**, porque su valor numérico está expresado en la misma dimensión de la variable manteniendo la magnitud.

Esta medida sí es la adecuada para establecer la variabilidad que presentan los valores observados de la variable, en su conjunto, con respecto a la media aritmética.

Observaciones $y = \{1, 3, 6, 10\}$

Media $\bar{x} = 5$

Varianza = $S^2 = 15,33$


$$s = \sqrt{\frac{[x_i - \bar{x}]^2}{n - 1}} \quad \longrightarrow \quad s = \sqrt{\frac{46}{3}} \quad \longrightarrow \quad s = \sqrt{15,33} \quad \longrightarrow \quad s = 3,91$$

Desvío estándar (cont.)

$$\bar{x} \pm aS$$

“Del promedio más o menos S”

La desviación estándar es un indicador sumamente importante con muchas aplicaciones. Por ejemplo, los estadísticos saben que cuando un conjunto de datos se distribuye de manera “normal”, el 68% de las observaciones de la distribución tiene un valor que se encuentra a menos de una desviación estándar de la media. También saben que el 96% de todas las observaciones tiene un valor no es mayor a la media más o menos dos desviaciones estándar (la Figura 18 grafica esta información).



Desvío estándar (cont.)

Ejercicio: Calcular el Desvío estándar de las observaciones que se obtuvieron de las edades de todos los detenidos en un operativo

Edad	19	24	30	45	23	51	39	44	26	23
------	----	----	----	----	----	----	----	----	----	----

$$n = 10$$

$$\bar{x} = 32,4$$

$$s^2 = 115,64$$

$$s = ?$$

Desvío estándar (cont.)

Ejercicio: Calcular el Desvío estándar de las observaciones que se obtuvieron de las edades de todos los detenidos en un operativo

Edad	19	24	30	45	23	51	39	44	26	23
------	----	----	----	----	----	----	----	----	----	----

$$n = 10$$

$$\bar{x} = 32,4$$

$$s^2 = 115,64$$

$$s = \sqrt{\frac{[x_i - \bar{x}]^2}{n}} \quad \rightarrow \quad s = \sqrt{115,64} \quad \rightarrow \quad \boxed{s = 10,75}$$

¿Qué quiere decir?

Desvío estándar (cont.)

Ejercicio: Calcular el Desvío estándar de las observaciones que se obtuvieron de las edades de todos los detenidos en un operativo

Edad	19	24	30	45	23	51	39	44	26	23
------	----	----	----	----	----	----	----	----	----	----


$$n = 10$$

$$\bar{x} = 32,4$$

$$s^2 = 115,64$$

$$s = 10,75$$

¿Qué quiere decir?



Coeficiente de Variación

Para poder establecer si la dispersión alrededor de la Media Aritmética que presenta una variable es baja o no, es necesario que el valor numérico del Desvío Estándar sea comparada o relacionada con ella, la Media.

El Coeficiente de Variación de la variable X , $CV(x)$, es el cociente entre el Desvío Estándar y la Media Aritmética.

$$CV = \frac{S(x)}{\bar{x}} * 100$$

El Coeficiente de Variación expresa la desviación estándar en porcentaje de la media.

Coeficiente de Variación (cont.)

El **Coeficiente de Variación** de la variable X, **CV(x)**, es el cociente entre el Desvío Estándar y la Media Aritmética.

$$CV = \frac{S(x)}{\bar{x}} * 100$$

Observaciones $y = \{1, 3, 6, 10\}$ Media $\bar{x} = 5$ Varianza $= S^2 = 15,33$ Desvío Estándar $= S = 3,91$

$$CV = \frac{S(x)}{\bar{x}} * 100 \quad \longrightarrow \quad CV = \frac{3,91}{5} * 100 \quad \longrightarrow \quad CV = 78,2\%$$

Coeficiente de Variación (cont.)

Ejercicio: Calcular el Coeficiente de Variación de las observaciones que se obtuvieron de las edades de todos los detenidos en un operativo

Edad	19	24	30	45	23	51	39	44	26	23
------	----	----	----	----	----	----	----	----	----	----

$$n = 10$$

$$\bar{x} = 32,4$$

$$s^2 = 115,64$$

$$s = 10,75$$

Coeficiente de Variación (cont.)

Ejercicio: Calcular el Coeficiente de Variación de las observaciones que se obtuvieron de las edades de todos los detenidos en un operativo

Edad	19	24	30	45	23	51	39	44	26	23
------	----	----	----	----	----	----	----	----	----	----

$$n = 10$$

$$\bar{x} = 32,4$$

$$s^2 = 115,64$$

$$s = 10,75$$

$$CV = \frac{s(x)}{\bar{x}} * 100$$



$$CV = \frac{10,75}{32,4} * 100$$



$$CV = 33,17\%$$

¿Qué quiere decir?

Unidad 3.3
Descripción de
datos.
Medidas de
Concentración

Marcelo Carballo Llosa
Maximiliano Vazquez



Medidas de concentración. Introducción

En el capítulo anterior, vimos que además de obtener una medida de tendencia central, media – mediana – moda, es necesario analizar el comportamiento de la totalidad de las observaciones y para ello es necesario calcular cómo es la dispersión de las observaciones entorno a la media. Vimos que existen 4 medidas principales para medir la dispersión de las observaciones de la variable, a través del Rango, Varianza, Desvío Estándar y Coeficiente de Variación.

El **Rango** es el recorrido de la variable obteniéndolo de la diferencia entre el valor máximo y el mínimo.

La **Varianza** es el promedio de las desviaciones de las observaciones en torno a la media elevadas al cuadrado. Vimos que se debían elevar al cuadrado porque la suma de los desvíos con respecto a la media se anulaban entre sí y el resultado era igual a cero.

El **Desvío estándar**, siendo cuanto se desvían en promedio las observaciones en relación a la medida de tendencia central.

Y por último, el **Coeficiente de Variación** que nos indica en que proporción de la media, el Desvío Típico, Estándar, se encuentra.

Medidas de Concentración

Cuando aprendimos a construir las tablas de frecuencia, vimos que existían dos medidas, **Frecuencia Absoluta Acumulada y Frecuencia Relativa Acumulada**, que nos permitían calcular cuantas unidades se acumulaban con valor de variable menor o igual a un valor dado. A estas dos **Medidas de Concentración**, se las obtiene partiendo desde las observaciones. Pero en el caso inverso, dado un valor de Frecuencia Relativa, hasta que valor de la variable se acumulan o concentran a esta medida se la conoce como **Percentil**.

El percentil es una medida de concentración usada en estadística que indica, una vez ordenados los datos de menor a mayor, el valor de la variable por debajo del cual se encuentra un porcentaje dado de observaciones en un grupo.



Percentiles:

<https://www.youtube.com/watch?v=s8QfGsVGurE>

Percentil

El percentil es un valor porcentual de la variable hasta donde se acumula cierta frecuencia relativa.

El **Percentil de Orden k**, correspondiente a la variable X , X_k , es el valor hasta donde se acumula, a lo sumo, el $k\%$ de las observaciones.

El **Percentil de Orden k**, no se ve afectado por valores extremos, pero sí por la forma en qué están agrupados los datos (variables continuas)

$$\text{Percentil Orden } k = (n + 1) \frac{P}{100}$$

n = número de observaciones

P = Percentil buscado ($k\%$)

El valor que se obtiene es el valor de la frecuencia absoluta acumulada y de ahí se debe buscar el valor correspondiente de la variable en la tabla de frecuencias.

Percentil (cont.)

Pasos para obtener el Percentil

1) Calcular el Orden del Percentil

$$\text{Percentil Orden } k = (n + 1) \frac{P}{100}$$

2) Ordenar las observaciones

3) Se busca en las Frecuencias Acumuladas el valor calculado y se le asigna el valor de la variable.

- A. En **Variables Discretas**, se busca el primer valor de frecuencia absoluta que supera al Percentil de Orden K.
- B. En **Variables Continuas**, se obtiene interpolando entre el valor de variable que obtenemos del orden y el siguiente.

Percentil - Ejemplo

Ejercicio: Calcular el percentil 30 de la siguiente muestra

Edad	19	24	30	45	23	51	39	44	26	23
------	----	----	----	----	----	----	----	----	----	----

Percentil - Ejercicio

Ejercicio: Calcular el percentil 30 de la siguiente muestra

Edad	19	24	30	45	23	51	39	44	26	23
------	----	----	----	----	----	----	----	----	----	----

$$n = 10$$

$$P = 30$$

1° Obtengo el Percentil de Orden 30

$$P_k = (n + 1) * \frac{P}{100}$$

$$PO_{30} = (10 + 1) * \frac{30}{100} = 3,3$$

2° Ordeno las observaciones y busco la posición

Edad	19	23	23	24	26	30	39	44	45	51
------	----	----	----	----	----	----	----	----	----	----



P30, posición 3,3, el valor **24** ya que es una variable discreta

Percentil - Ejercicio

Ejercicio: Se obtienen los últimos 10 tickets de compras del supermercado y s quiere saber:

1. El percentil 10 de la siguiente muestra
2. El percentil 90 de la siguiente muestra
3. Que conclusiones se pueden obtener?

Ticket	6.238	281	8.486	6.553	8.961	6.651	3.956	5.181	1.616	5.220
--------	-------	-----	-------	-------	-------	-------	-------	-------	-------	-------

Percentil - Ejercicio

1. El percentil 10 de la siguiente muestra
2. El percentil 90 de la siguiente muestra
3. Que conclusiones se pueden obtener?

1° Obtengo el Percentil de Orden 10

$$P_k = (n + 1) * \frac{P}{100}$$

$$PO_{10} = (10 + 1) * \frac{10}{100} = 1,1$$

2° Ordeno las observaciones y busco la posición

Ticket	281	1.616	3.956	5.181	5.220	6.238	6.553	6.651	8.486	8.961
--------	-----	-------	-------	-------	-------	-------	-------	-------	-------	-------

Cómo es una variable continua, y el resultado no es entero, debo interpolar agregándole al valor de la observación 1°, la diferencia entre el valor de la observación 2° y la 1° por el resto del PO (0,1)

3° Interpolación

$$PO_{10} = 281 + (1616 - 281) * 0,1 = 414,5$$

Percentil - Ejercicio

1. El percentil 10 de la siguiente muestra
2. El percentil 90 de la siguiente muestra
3. Que conclusiones se pueden obtener?

1° Obtengo el Percentil de Orden 90

$$P_k = (n + 1) * \frac{P}{100}$$

$$PO_{90} = (10 + 1) * \frac{90}{100} = 9,9$$

2° Ordeno las observaciones y busco la posición

Ticket	281	1.616	3.956	5.181	5.220	6.238	6.553	6.651	8.486	8.961
--------	-----	-------	-------	-------	-------	-------	-------	-------	-------	-------

Cómo es una variable continua, y el resultado no es entero, debo interpolar agregándole al valor de la observación 1°, la diferencia entre el valor de la observación 9° y la 10° por el resto del PO (0,9)

3° Interpolación

$$PO_{90} = 8486 + (8961 - 8486) * 0,9 = 8913,5$$

Percentiles “Especiales”

Los Percentiles son muy útiles, y casi fundamentales, para entender el comportamiento de una variable, entendiendo como es que se concentran las observaciones a lo largo del recorrido de la variable. El método habitual de empleo de esta medida consiste en determinar la ubicación de los valores que dividen un conjunto de observaciones en partes iguales. Estas medidas se las suele agrupar en cuartiles, deciles o quintiles.

Cuartiles: Los cuartiles dividen a un conjunto de observaciones en cuatro partes iguales.

Percentil: 25, 50, 75, 100

Se las suele escribir como Q1, Q2, Q3 respectivamente

Mediana es:

- Percentil 50
- Decil 5
- Cuartil 2

Quintiles: Los quintiles dividen a un conjunto de observaciones en cinco partes iguales.

**Percentil: 20, 40, 60, 80,
100**


Deciles: Los deciles dividen a un conjunto de observaciones en 10 partes iguales.

Percentil: 10, 20, 30, 40, 50, 60, 70, 80, 90, 100

Rango Intercuartílico

El **Rango Intercuartílico** mide la dispersión que hay en el 50 por ciento central de los datos; es la diferencia entre la observación del Q3, el **Tercer Cuartil**, y la observación del Q1, **Primer Cuartil**,

$$RIC = Q3 - Q1$$



Resumen de los cinco números



Habitualmente cuando uno quiere explicar de forma resumida el comportamiento de una variable en estudio lo suele hacer a través de las cinco medidas que estuvimos viendo hasta ahora:

$$\textit{Mínimo} < Q1 < \textit{Mediana} < Q3 < \textit{Máximo}$$

De esta manera vamos a poder saber cual es el punto central, como se dispersan los datos y cual es el recorrido de la variable.

Resumen de los cinco números (cont.)

La forma mas habitual para presentar estos datos es mediante el gráfico de Cajas o Diagrama de Cajas.




Estos gráficos, no solo que son una forma muy útil de **resumir** la información, sino que nos permiten **comparar** el comportamiento de dos observaciones o mas observaciones pudiendo detectar sus diferencias y similitudes.

Resumen de los cinco números (cont.)

Diagrama de Cajas sobre las observaciones de los últimos 10 tickets obtenidos del Supermercado

Ticket	281	1.616	3.956	5.181	5.220	6.238	6.553	6.651	8.486	8.961
--------	-----	-------	-------	-------	-------	-------	-------	-------	-------	-------




$$RIC = Q3 - Q1$$

$$RIC = 7110 - 3371 = 3739$$

Resumen de los cinco números (cont.)

Diagrama de Cajas. Comparativo Resultado Primera Evaluación Estadística



¡Gracias!

